

VGIB-HGNN: Uncertainty-Aware Multimodal Graph

Mining for Cognitive Risk Stratification under Weak

Alignment

摘要 Abstract

輕度認知障礙（Mild Cognitive Impairment, MCI）被視為正常老化與失智症之間的重要過渡階段，也是客觀認知障礙尚未進展為明確失智症前的關鍵風險狀態。因此，早期認知風險篩檢的首要定位是最大化潛在高風險個案的召回率（High-Recall），而非最終的臨床分類診斷。為實現敏感的風險分層，結合「腸腦軸」的多模態學習已成為新興趨勢；然而，整合中樞神經影像（Brain MRI）與周邊生物訊號（腸道菌相）面臨著「弱對齊（Weak Alignment）」的挑戰，這兩種截然不同的模態缺乏穩定的特徵一對一對應，且極易受環境雜訊干擾。為了解決此限制，本文提出 VGIB-HGNN-Focal 圖學習框架。我們首先建構「患者-物種異質圖」，在不強制進行特徵對齊的前提下自然保留多模態的關係拓撲；進一步引入「變分圖資訊瓶頸（VGIB）」層來約束隱空間的表徵容量，從而有效壓縮弱對齊所帶來的冗餘雜訊；最後，整合風險敏感的「Focal Loss」以優化極端類別不平衡下的模型訓練。在 454 位真實受試者資料上，VGIB-HGNN-Focal 於 Risk Recall (0.843) 與 Risk F1 (0.657) 指標上均取得最佳效能。成對 Bootstrap 檢定證實，相較於 RF-AllTabular，本框架於 Risk Recall 上顯著提升了 +0.065 ($p = 0.033$)；相較於 MLP-Focal，則在維持同等召回下將 Risk Precision 拉高了 +0.055 ($p < 0.001$)。結果支持認知功能退化可分成篩檢與診斷兩階段，而本研究提供了一套適用於初次風險篩檢的圖學習架構。

一、介紹 (Introduction)

失智症已成為全球重大的公共衛生議題，醫學界最新實證研究指出，約 45% 的個案可透過早期的風險因子控管來達成預防或延緩 [1]。在認知退化光譜中，輕度認知障礙 (Mild Cognitive Impairment, MCI) 被視為正常老化與失智症之間的重要過渡階段，也是早期認知風險篩檢中的關鍵風險狀態。該階段的風險篩檢本質上已從傳統的「臨床診斷分類任務」轉向「高召回率 (High-Recall) 風險分層任務」。其目的是在可接受的假陽性上限內，最大化潛在高風險個案的召回能力，以便在發生不可逆的神經損傷前，將後續高密度的醫療追蹤資源精準配置給失智症之潛在高風險人群。

過去臨床上多依賴驗血或腦部影像進行失智症診斷。然而，血液檢驗所能提供的中樞神經訊息相對微弱；而腦部核磁共振 (Brain MRI) 則面臨受檢者自費意願低、難以長時間配合掃描，以及操作技術差異導致測量誤差等挑戰。因此，整合多面向數據進行失智症診斷，是當前精準醫療的重要研究導向。然而，在跨模態的數據資料處理上，該如何有效處理「非對稱異質模態間的語義對齊」，並「抑制無關雜訊所帶來的幻覺與誤判」，仍是一大問題。

為了捕捉這些微弱的早期異常，跨模態生物醫學資料探勘領域當前的一大前沿趨勢，即是圍繞「腸腦軸 (Gut-Brain Axis)」進行多模態融合，將巨觀的中樞神經影像 (Brain MRI) 與微觀的周邊生物標記 (腸道菌相) 進行有機整合 [2, 5]。然而，這引入了核心技術挑戰：弱對齊 (Weak Alignment)。不同於具備穩定同步關係的傳統多模態資料，弱對齊意味著模態間缺乏逐點對應，底層關聯呈現出跨尺度的非線性耦合。以腸腦軸為例，腸道菌相豐度極易受外部環境干擾，與 Brain MRI 所反映的中樞神經退化指標之間，本質上即體現了這種非同步且異質的弱對齊特徵。在此類跨模態且弱對齊的模態關係下，單純 early fusion 或強制 alignment 可能難以充分保留各模態的非冗餘訊號，甚至增加不穩定關聯對模型決策的影響 [3, 4]。

更關鍵的是，腸道菌相在本質上提供了一種跨個體的群體結構訊號。個體間若具備相似的微生物組成，往往隱含著相似的生物代謝或微環境特徵，這使得菌相成為連接不同受試者間的「關係錨點 (Relational Anchors)」。透過建構圖結構，腸道菌相不再僅是單純的輸入特徵，而是轉化為跨患者的訊息路由機制。這種建模方式允許大腦結構表徵在相似的微生物環境背景下進行資訊交互與增強，從而捕捉那些在單一樣本特徵空間中難以被顯現、具備集體模式的生物醫學訊號 [14, 15]。

儘管近年深度多模態學習與異質圖神經網路 (HGNN) 在醫療健康資訊學中取得了重要進展，特別是在整合臨床變量與透過患者相似性結構進行群體建模方

面展現了卓越效能 [6]。然而，現有方法普遍將周邊生物訊號（如腸道菌相資料）視為封裝在患者節點內部的扁平表格特徵（Flat Tabular Features）。這種方式忽略了受試者與不同微生物菌種之間跨群體的複雜關係拓撲。更重要的是，既有的圖架構並未建立明確的計算機制來量化模態不確定性，或過濾跨模態中的任務冗餘表徵雜訊。為了彌補這些研究盲點，本研究直接建構顯式的患者-物種異質圖以完整保留關係訊號。不過這種拓撲架構的引入，也使模型面對「弱對齊（Weak Alignment）」帶來的嚴峻考驗，因為外周菌相作為間接且深受環境干擾的互補訊號，會伴隨巨量的交互雜訊。為了解決此項伴隨而來的核心挑戰，本文提出 VGIB-HGNN-Focal 框架，引入「變分圖資訊瓶頸」層，將患者圖嵌入表徵投射至高斯隱空間並透過 KL 散度進行嚴格正則化，從而壓縮弱對齊多模態中的任務冗餘雜訊，提煉出最小充分表徵 [7]，最後整合風險敏感的「Focal Loss」，強制模型將優化焦點轉向少數且困難的高風險樣本，以符合高召回篩檢的根本任務需求 [8]。

本文的核心貢獻如下：

- **弱對齊特性的量化與實證 (Quantification of Weak Alignment):** 本研究假設腦部影像與腸道菌相資料之間未必存在穩定的直接對應關係，而可能呈現低對齊但互補的資料特性。因此，將多模態認知風險分析從傳統的直接融合問題，重新定位為弱對齊多模態資料下的風險分層問題。
- **不確定感知圖表示學習框架 (Uncertainty-Aware Graph Framework):** 針對弱對齊資料中可能產生的偽相關、雜訊融合與冗餘資訊問題，本研究建構 VGIB-HGNN-Focal 框架，透過異質圖結構與變分資訊瓶頸機制，學習更穩健且與認知風險相關的跨模態表示。
- **多維度基線比較與實證 (Comprehensive Baseline Comparison):** 本研究將評估重點由單純分類準確率延伸至高召回率風險篩檢、邊界個案分析與臨床決策透明度，期望推動認知風險辨識從確診導向的二元分類，轉向更適合早期預防的風險分層與輔助決策模式。

二、相關文獻 (Related Work)

2.1 多模態學習與弱對齊 (Multimodal Learning and Weak Alignment)

傳統的多模態學習通常依賴於早期融合 (Early Fusion) 或深度表示對齊策略 (如深度典型相關分析, Deep CCA), 試圖將不同來源的特徵映射到一個共享的緊密隱空間中, 這預設了模態間存在強烈的時空同步或語意等價關係 [9, 10]。然而, 在現實世界的許多複雜場景中, 如未對齊的序列 (Unaligned Sequences) 或多光譜檢測所示, 受限於採樣率不一致或感測器異質性, 這種硬性對齊假設往往難以成立, 無法正確呈現個體間的同質或異質差異 [3, 4]。現有應對非對齊多模態的研究, 多聚焦於利用動態時間規整 (DTW) 或注意力交叉機制來捕捉弱相關性, 但這仍高度依賴特徵間的潛在順序性。

在生物醫學的腸腦軸 (Gut-Brain Axis) 建模背景下, 整合中樞神經影像 (Brain MRI) 與周邊生物訊號 (腸道菌相) 本質上屬於更嚴苛的弱對齊問題 [2]。外周菌相特徵極易受到飲食、藥物等外部環境干擾, 與大腦巨觀結構的退化之間缺乏任何直接的一對一特徵映射或同步演進關係。傳統基於硬性空間對齊或簡單特徵串接的方法, 在面對此類異質模態時, 往往會引入大量的任務冗餘雜訊。因此, 如何在缺乏明確特徵對齊的前提下, 有效過濾跨模態環境雜訊並學習各模態特有的非冗餘互補訊號, 已成為多模態醫療資訊學中待解決的瓶頸。

2.2 生物醫學圖神經網路與腸腦軸風險建模

為了解決傳統多模態學習難以處理非獨立同分布 (Non-I.I.D.) 醫療資料的限制, 圖神經網路 (Graph Neural Networks, GNNs) 與異質圖神經網路

(Heterogeneous Graph Neural Networks, HGNNs) 近年已成為生物醫學資料探勘中的重要方法。相較於將每位受試者視為彼此獨立的樣本點, 圖式建模能透過患者相似性、腦區連結或疾病相關生物實體之間的關係, 捕捉臨床族群中潛在的結構性訊號。在認知障礙與阿茲海默症研究中, 既有圖學習方法多聚焦於功能性腦網路、結構性腦影像特徵, 或以臨床變量建構 patient similarity graph, 藉此將醫療資料由孤立的表格樣本轉化為具拓撲結構的關係網絡。

在腦部影像方面, 結構性 MRI 能提供與中樞神經退化相關的直接證據, 尤其是內側顳葉區域。既有 MRI volumetry 研究指出, entorhinal cortex 與 hippocampus 在 MCI 與 AD 階段已可觀察到體積下降, 因此常被視為早期認知退化的重要影像標記 [16], [17]。系統性回顧與統合分析亦顯示, MCI 受試者在 hippocampus、whole brain 與 entorhinal cortex 的體積流失較正常老化者更明顯 [17]。此外, amygdala atrophy 也被指出在早期 AD 中相當突出, 且可能與症狀嚴重度相關 [18]。因此, 本研究將 hippocampus、amygdala 與

entorhinal cortex 作為主要 brain ROI features，並將其納入 patient node features，用以表徵受試者的中樞神經退化風險。

然而，腦部 MRI 主要反映已累積的結構性萎縮，未必能完整捕捉失智症早期更間接的周邊生物變化。近年腸腦軸（microbiota–gut–brain axis）研究指出，腸道菌相可能透過慢性發炎、免疫調節、代謝物、血腦屏障與神經發炎等機制，與 AD/MCI 的發展產生關聯。Vogt 等人發現 AD 受試者的 gut microbiome diversity 較低，且菌群組成與健康對照組不同，包含 Firmicutes、Bacteroidetes 與 Bifidobacterium 等分類群差異 [19]。Cattaneo 等人則指出，brain amyloidosis 可能與 pro-inflammatory gut bacterial taxa 及 peripheral inflammation markers 有關，支持腸道菌相可能透過發炎途徑參與認知退化相關病理 [20]。不過，腸道菌相高度受到飲食、藥物、生活型態與個體差異影響，不同研究對具體菌種方向的發現並不完全一致。因此，microbiome 更適合被理解為反映周邊發炎、免疫與代謝環境的高維互補訊號，而非單一穩定的診斷標記 [21]。

基於上述特性，若僅將腸道菌相視為患者節點內部的扁平表格特徵（flat tabular features），可能會忽略菌種在不同患者之間形成的跨群體關係。特別是在腸腦軸導向的認知風險分層任務中，brain MRI 與 microbiome 分別代表「中樞神經結構退化」與「周邊生物環境異常」兩類訊號；兩者具有互補性，但不一定存在穩定的一對一特徵對齊。因此，本研究將 microbiome species 從表格欄位提升為 patient–species heterogeneous graph 中的顯式 species nodes，使其能作為跨患者的 relational anchors。此設計允許 HGNN 在不強制 brain–microbiome 特徵對齊的情況下，透過患者—菌種關係保留弱對齊多模態資料中的互補拓撲訊號。

2.3 拓撲圖資訊瓶頸與風險敏感學習 (Graph Information Bottleneck and Risk-Sensitive Learning)

針對圖神經網路在高維特徵與複雜拓撲中容易聚合冗餘訊息並產生過擬合的問題，資訊瓶頸（Information Bottleneck, IB）原則提供了一種重要的表示學習觀點。IB 的核心目標是在保留與預測任務相關資訊的同時，壓縮輸入中與目標無關的冗餘變異，進而學習更精簡且具泛化能力的表徵 [13]。Graph Information Bottleneck (GIB) 進一步將此概念延伸至圖結構資料，透過約束輸入圖、節點特徵與隱表徵之間的資訊流動，降低模型對雜訊特徵或不穩定拓撲關係的依賴，提升圖表示學習在噪聲環境下的穩健性 [7]。

在生物醫學異質圖場景中，資訊壓縮機制尤其具有重要意義。醫療資料通常同時包含高維特徵、量測誤差等問題；當圖神經網路進行鄰域訊息聚合時，若缺乏適當的正則化，模型可能將與疾病風險無關的群體差異一併編碼至隱表徵

中。此問題在弱對齊多模態資料中更為明顯，因為不同模態間缺乏穩定的一對一對應，直接聚合可能放大跨模態間的相關。

另一方面，認知風險篩檢任務也面臨類別不平衡與邊界樣本辨識困難的挑戰。在真實臨床篩檢情境中，高風險個案通常佔比較低，傳統交叉熵損失容易偏向多數類別，導致模型雖可取得較高整體準確率，卻可能漏判真正需要追蹤的高風險受試者。Focal Loss 透過降低易分類樣本的損失權重，並提升困難樣本與少數類別的學習比重，已被廣泛用於類別不平衡與困難樣本辨識問題 [8]。因此，對於早期認知風險分層而言，風險敏感學習不僅是模型訓練技巧，更與篩檢任務中「優先提高高風險召回率」的實務目標一致。

三、預備知識 (Preliminary)

3.1 患者—物種異質圖形式化

本文將腦-菌相認知風險篩檢任務建模為患者-物種異質圖上的表示學習問題。令 N 與 S 分別表示臨床佇列中的受試者數量與選定的腸道菌種數量。我們定義拓撲異質圖為 $G = (\mathcal{V}_p, \mathcal{V}_s, \mathcal{E}_{ps})$ ，其中 $\mathcal{V}_p = \{v_1^p, \dots, v_N^p\}$ 表示患者節點集合， $\mathcal{V}_s = \{v_1^s, \dots, v_S^s\}$ 表示菌種節點集合，而 $\mathcal{E}_{ps}$ 則為患者-物種間二部關聯邊的集合。對於每個患者節點 v_i^p ，其初始多模態特徵向量 x_i^p 定義為中樞神經影像特徵與多維臨床協變量的顯式串接：

$$x_i^p = [x_i^{\text{demographic}} \parallel x_i^{\text{brain}}], \quad (1)$$

其中 x_i^{brain} 包含由海馬體 (Hippocampus)、杏仁核 (Amygdala) 及內嗅皮質 (Entorhinal Cortex) 等關鍵腦區構成的感興趣區域 (ROI) 體積特徵。

$x_i^{\text{demographic}}$ 則涵蓋年齡、性別、教育程度與 BMI 等臨床生理協變量，在此異質圖形式化設定中，這些臨床生理指標並非作為獨立的數據模態，而是作為受試者本體的基礎生理背景屬性。此設計旨在為受試者節點建立更宏觀、立體的臨床輪廓，為隨後的跨模態圖嵌入學習提供不可或缺的群體上下文資訊。

若受試者 i 體內檢測出菌種 j 的存在，則在圖中建立一條非定向邊 $e_{ij} = (x_i^p, v_j^s) \in \mathcal{E}_{ps}$ 。其邊屬性 (Edge Attribute) a_{ij} 可根據下游任務需求，透過豐度 (Abundance-based) 反應量化特質或存在性 (Presence-based) 進行質化分析：

$$a_{ij} = \begin{cases} \log(1 + \text{abundance}_{ij}), & \text{abundance-based} \\ I(\text{abundance}_{ij} > 0), & \text{presence-based} \end{cases}, \quad (2)$$

其中 $I(\cdot)$ 為指示函數。藉由將微生物菌種從傳統的扁平表格特徵 (Flat Tabular Features) 提升為圖結構中的顯式節點，使其得以充當跨患者群體的關係錨點 (Relational Anchors)。這種拓撲形式化範式允許異質圖神經網路 (HGNN) 在進行鄰域訊息傳遞時自然地凝聚跨模態生物訊號，而無需迫使菌相與大腦結構特徵進行不自然的特徵一對一對齊。然而，此類跨尺度多模態資料間是否確實存在弱對齊狀態，仍需透過具體的指標進行經驗檢驗。因此本研究於 3.2 節進一步引入多維度的量化評估流程，以實證並特性化 (Characterize) 腦-菌相資料間的弱對齊現象。

3.2 弱對齊的經驗判準

為了評估中樞神經影像與周邊菌相之間是否存在弱對齊，本研究在 brain representation $\mathbf{B} \in R^{N \times d_b}$ 與 microbiome representation $\mathbf{M} \in R^{N \times d_m}$ 上建立判斷準則，分別為跨模態可預測性、典型相關分析、鄰域重疊度與風險標記不一致性。前三者用於衡量兩個模態在 latent representation 與 patient-neighborhood

structure 上的對齊程度；第四者則進一步檢查 brain-related risk markers 與 microbiome-related risk markers 是否指向相同的高風險病人子群。

- **跨模態可預測性 (Cross-modal Predictability):** 以交叉驗證迴歸函數 $f(\cdot)$ 與 $g(\cdot)$ 衡量一個模態是否能重建另一個模態的低維表徵結構。令 B_i 與 M_i 分別表示第 i 位受試者的 brain representation 與 microbiome representation, 則 microbiome-to-brain 與 brain-to-microbiome 的 cross-modal predictability 定義為:

$$R_{M \rightarrow B}^2 = 1 - \frac{\sum_{i=1}^N \|B_i - f(M_i)\|_2^2}{\sum_{i=1}^N \|B_i - \bar{B}\|_2^2}, \quad (3)$$

$$R_{B \rightarrow M}^2 = 1 - \frac{\sum_{i=1}^N \|M_i - g(B_i)\|_2^2}{\sum_{i=1}^N \|M_i - \bar{M}\|_2^2}, \quad (4)$$

其中 $\bar{B}$ 和 $\bar{M}$ 分別為 brain representation 與 microbiome representation 的樣本平均。若 $R_{B \rightarrow M}^2$ 或 $R_{M \rightarrow B}^2$ 接近零或為負值, 代表其中一個模態難以可靠重建另一個模態的 latent structure, 顯示兩者缺乏穩定的跨模態可預測性。

- **典型相關分析 (CCA):** 藉由評估兩個模態是否存在共享線性 latent space。CCA 尋找投影向量 u 與 v , 使 brain representation 與 microbiome representation 在投影後的相關性最大化:

$$\rho = \max_{u,v} \text{corr}(\mathbf{B}u, \mathbf{M}v). \quad (5)$$

若前幾個 canonical components 的 ρ 值偏低, 表示 brain 與 microbiome 缺乏穩定的共享線性子空間, 亦支持 weak latent alignment 的判斷。

- **鄰域重疊度 (Neighborhood Overlap):** 令 $\mathcal{N}_B^k(i)$ 與 $\mathcal{N}_M^k(i)$ 分別表示患者 i 在腦空間與菌相空間中的 k 近鄰。鄰域重疊度定義為:

$$\text{Overlap}_{@k} = \frac{1}{Nk} \sum_{i=1}^N |\mathcal{N}_B^k(i) \cap \mathcal{N}_M^k(i)|. \quad (6)$$

若 $\text{Overlap}_{@k}$ 很低, 代表在 brain space 中相似的病人, 通常不會在 microbiome space 中同樣相似。此結果說明兩個模態不僅在 latent

representation 上可能不一致，其 patient similarity topology 也可能存在顯著差異。

- **風險標記不一致性 (Inconsistent risk labeling):**


除了表徵與鄰域結構，本研究進一步從風險相關生物指標的角度檢查兩個模態是否指向相同的高風險病人子群。具體而言，本研究分別建構 brain-related risk score 與 microbiome-related risk score。Brain-related risk score 由 hippocampus、amygdala 與 entorhinal cortex 等與認知退化相關的 brain markers 組成；microbiome-related risk score 則由 microbiome diversity、microbiome principal components 以及具顯著或探索性差異的菌種特徵組成。接著，本研究比較兩者的 Spearman correlation，並計算兩個模態各自 top-q high-risk marker groups 的 Jaccard overlap：

$$\text{Jaccard}_q = \frac{|\mathcal{H}_B^q \cap \mathcal{H}_M^q|}{|\mathcal{H}_B^q \cup \mathcal{H}_M^q|}, \quad (7)$$

其中 $\mathcal{H}_B^q$ 表示依 brain-related risk score 排名前 q% 的受試者集合， $\mathcal{H}_M^q$ 則表示依 microbiome-related risk score 排名前 q% 的受試者集合。若兩個 risk scores 的相關性低，且 Jaccard_q 亦低，表示 brain-related 與 microbiome-related markers 所指向的 high-risk candidate subsets 並不一致。此結果可視為 risk-marker level 的 weak alignment evidence。

四、方法 (Methodology)

本節介紹本文所提出的 VGIB-HGNN-Focal 框架，如 Figure 1 所示。本框架包含三個核心模組：(1) 捕捉跨模態關係的異質圖編碼器；(2) 處理弱對齊雜訊的變分圖資訊瓶頸層，以及 (3) 針對高風險篩檢的風險敏感優化目標。以下詳述各模組之技術細節。



VGIB – HGNN – Focal integrates weakly aligned microbiome relations through a patient-species graph, while Gaussian IB filters noisy multimodal signals for risk-sensitive screening.

Figure.1 VGIB – HGNN – Focal Model Architecture

4.1 異質圖訊息傳遞 (Heterogeneous Graph Message Passing)

基於 3.1 節定義的異質圖 $\mathcal{G}$ ，為了整合患者與菌種節點之間的弱對齊關係，本研究採用特定關係的異質圖訊息傳遞機制。在每一層 HGNN 中，患者節點的隱藏表示會根據其相鄰的菌種節點與邊屬性進行更新。第 l 層的患者節點更新規則如下：

$$h_i^{p,(l+1)} = \sigma \left(\sum_{j \in \mathcal{N}_s(i)} \alpha_{ij}^{(l)} \mathbf{w}^{(l)} h_j^{s,(l)} \right), \quad (8)$$

其中 $\mathcal{N}_s(i)$ 表示與患者 i 相連的菌種鄰居集合， $\mathbf{w}^{(l)}$ 為可學習的轉換矩陣， $\sigma(\cdot)$ 為非線性激活函數。 $\alpha_{ij}^{(l)}$ 為注意力權重 (Attention weight)，用於評估不同患者與菌種關係對風險預測的貢獻度：

$$\alpha_{ij}^{(l)} = \text{softmax}_j \left(\text{LeakyReLU} \left(a^\top \left[\mathbf{w} h_i^{p,(l)} \parallel \mathbf{w} h_j^{s,(l)} \parallel a_{ij} \right] \right) \right), \quad (9)$$

其中， $\mathbf{a}^\top$ 為注意力機制中可學習的參數向量（Learnable attention vector）， $\parallel$ 表示特徵串接操作。 $\alpha_{ij}^{(l)}$ 則是經過 Softmax 歸一化後所得的標量係數，體現了模型在訊息聚合過程中對鄰域節點的關注度。此設計使微生物菌相不再僅是扁平的表格特徵，而是作為跨患者的關係訊號（Relational signals）被整合。透過此物種節點的訊息聚合與傳遞，模型能在缺乏明確特徵對齊的情況下，隱式地學習腸腦軸的互補關聯。

4.2 變分圖資訊瓶頸 (Variational Graph Information Bottleneck)

在弱對齊的多模態設定中，直接融合訊號極易使模型過擬合於環境雜訊或不穩定的假性相關（Spurious correlations）。為此我們在 HGNN 編碼器後引入 VGIB 層。令 $\mathbf{h}_i$ 表示 HGNN 輸出的患者表徵，VGIB 將其投射為高斯隱分佈的均值與變異數：

$$\boldsymbol{\mu}_i = f_\mu(\mathbf{h}_i), \quad \log \sigma_i^2 = f_\sigma(\mathbf{h}_i) . \quad (10)$$

接著，我們定義患者的隱表徵後驗分佈為 $q_\phi(\mathbf{z}_i | \mathbf{h}_i) = \mathcal{N}(\boldsymbol{\mu}_i, \text{diag}(\sigma_i^2))$ 。為使模型支援反向傳播，我們採用重參數化技巧（Reparameterization trick）進行採樣：

$$\mathbf{z}_i = \boldsymbol{\mu}_i + \sigma_i \odot \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(0, \mathbf{I}) . \quad (11)$$

此機制將確定性的節點嵌入轉換為具備不確定性感知的隱分佈。為了實踐資訊瓶頸的正則化，我們最小化後驗分佈與標準高斯先驗 $p(\mathbf{z}) = \mathcal{N}(0, \mathbf{I})$ 之間的 KL 散度（KL divergence）。對於對角高斯分佈，其封閉形式為：

$$\mathcal{L}_{\text{KL}} = -\frac{1}{2} \sum_{k=1}^{d_z} (1 + \log \sigma_{ik}^2 - \mu_{ik}^2 - \sigma_{ik}^2) . \quad (12)$$

透過最小化 $\mathcal{L}_{\text{KL}}$ ，模型被迫限制隱表徵的資訊容量，進而壓縮與風險預測無關的弱對齊雜訊，確保表徵的穩健性。

4.3 風險敏感目標優化 (Risk-Sensitive Optimization)

早期認知風險篩檢的首要目標是最大化潛在高風險個案的召回率，這本質上是一個類別極度不平衡的學習任務。我們採用 Focal Loss 使模型更關注困難樣本

(Hard examples) 與少數的高風險類別。令模型對類別 $y_i = 1$ (MCI 與失智症) 的預測機率為：

$$\hat{p}_i = P(y_i = 1 | \mathbf{z}_i) . \quad (13)$$

對於真實類別 $y_i \in \{0,1\}$ ，我們定義 $p_{t,i}$ 如下：

$$p_{t,i} = \begin{cases} \hat{p}_i, & \text{if } y_i = 1 \\ 1 - \hat{p}_i, & \text{if } y_i = 0 \end{cases} . \quad (14)$$

Focal Loss 的目標函數定義為：

$$\mathcal{L}_{Focal} = -\alpha_t (1 - p_{t,i})^\gamma \log(p_{t,i}) . \quad (15)$$

其中 α_t 用於平衡類別權重，聚焦參數 γ 用於降低已受良好分類（高信心度）樣本的損失權重，強迫模型專注於難以識別的高風險邊界個案。

最終，本研究的完整優化目標結合了 Focal Loss 與資訊瓶頸正則化：

$$\mathcal{L} = \mathcal{L}_{Focal} + \beta \mathcal{L}_{KL} , \quad (16)$$

其中 β 控制 VGIB 壓縮雜訊的強度。整體的訓練與優化過程如 Algorithm 1 所示。

Algorithm 1 Training Procedure of VGIB-HGNN-Focal

Require: $\mathbf{X}^{demographic}, \mathbf{X}^{brain}, \mathbf{A}, \mathbf{y}, \gamma, \beta$

Ensure: Trained model and risk probabilities $\hat{\mathbf{p}}$

- 1: Construct patient node features: $\mathbf{X}^p = [\mathbf{X}^{demographic}; \mathbf{X}^{brain}]$
 - 2: Construct species node set $\mathcal{V}_s$
 - 3: **for** each patient i and species j **do**
 - 4: **if** $A_{ij} > 0$ **then**
 - 5: Create edge $e_{ij} = (v_i^p, v_j^s)$
 - 6: Assign edge attribute a_{ij}
 - 7: **end if**
 - 8: **end for**
 - 9: Initialize HGNN encoder θ , Gaussian IB parameters ϕ , and classifier ψ
 - 10: **for** each training epoch **do**
 - 11: $\mathbf{h}_i \leftarrow \text{HGNN}_\theta(G, \mathbf{X}^p, \mathbf{X}^s, a_{ij})$
 - 12: Obtain latent distribution: $\boldsymbol{\mu}_i \leftarrow f_\mu(\mathbf{h}_i)$, $\log \sigma_i^2 \leftarrow f_\sigma(\mathbf{h}_i)$
 - 13: Sample $\boldsymbol{\epsilon} \sim \mathcal{N}(0, \mathbf{I})$
 - 14: Reparameterize: $\mathbf{z}_i \leftarrow \boldsymbol{\mu}_i + \sigma_i \odot \boldsymbol{\epsilon}$
 - 15: Predict risk: $\hat{p}_i \leftarrow \text{Classifier}_\psi(\mathbf{z}_i)$
 - 16: $\mathcal{L}_{Focal} \leftarrow \text{FocalLoss}(\hat{p}_i, y_i; \gamma)$ ▷ Apply γ for class imbalance
 - 17: $\mathcal{L}_{KL} \leftarrow D_{KL}(q_\phi(\mathbf{z}_i | \mathbf{h}_i) \| \mathcal{N}(0, \mathbf{I}))$
 - 18: $\mathcal{L} \leftarrow \mathcal{L}_{Focal} + \beta \mathcal{L}_{KL}$ ▷ Optimize with IB constraint β
 - 19: Update model parameters θ, ϕ, ψ via backpropagation
 - 20: **end for**
 - 21: **return** Trained model and risk probabilities $\hat{\mathbf{p}}$
-

五、實驗與結果 (Experiments and Results)

5.1 實驗設定 (Experimental Setup)

本研究以二元認知風險篩檢 (Binary Cognitive Risk Screening) 作為核心評估任務，將臨床佇列中的受試者劃分為正常組 (Normal, $y = 0$) 與具備認知風險組 (Risk, $y = 1$)，其中風險組由輕度認知障礙 (MCI) 與失智症 (Dementia) 患者共同構成。

本研究資料集共包含 454 位受試者，其中包含 346 位 Normal 與 108 位 Risk subjects (Risk = MCI + Dementia)。輸入資料包含 demographic covariates、brain ROI volumetric features 與 gut microbiome profiles。其中，demographic covariates 包含年齡、性別、教育年限、BMI、吸菸、飲酒與運動天數等共 7 維特徵；brain ROI features 則聚焦於雙側 hippocampus、amygdala 與 entorhinal cortex，並進一步建構左右側原始體積、雙側平均值、左右差值、不對稱性比率，以及以 total brain volume 正規化後的 ROI 體積，共 21 維特徵。Gut microbiome profiles 則先依 prevalence threshold 進行初步過濾，再依全域變異數選取變異最大的 $S=50$ 個 species，作為 patient-species heterogeneous graph 中的 species nodes 與 microbiome relation construction 基礎。

為了清晰呈現多模態資訊與圖結構表徵方式的增量貢獻，本研究將基準模型的特徵輸入設定區分為以下兩類：

- Brain_demographic: 僅輸入 28 維的臨床協變量與大腦 MRI 特徵，不包含任何腸道菌相資訊，用以作為基礎預測表現的對照基準 (Baseline)。
- AllTabular: 將精選出的 50 個菌相資料視為高維的扁平表格欄位 (Flat Features)，直接與臨床和大腦特徵進行串接 (Concatenation) 後輸入模型。

此設計旨在與本文所提出的圖架構 (Graph-Based Setting) 進行對比，以實證將菌相資料建模為「患者-物種異質圖」而非傳統表格欄位，能更有效捕捉弱對齊多模態中的互補關係訊號。本研究將提出的 VGIB-HGNN-Focal 與多種基線模型進行全面比較，包含傳統機器學習 (LogReg, RF)、深度表格神經網路 (MLP-Focal)，以及圖神經網路變體 (HGNN-CE, HGNN-Focal, HGNN-Gaussian-Focal)。評估指標涵蓋 AUC、PR-AUC、Macro-F1、Risk Recall、Risk Precision、Risk F1。由於本研究聚焦於高風險早期篩檢，因此 Risk Recall 與 Risk F1 為最核心的評價指標。所有評估皆結合 5-Fold 交叉驗證、重複隨機種子 (Repeated-Seed) 穩健性分析與成對 Bootstrap 顯著性檢定，以確保實驗結果之統計穩健性。

5.2 複雜度與運行效率分析 (Complexity Analysis)

為了評估 VGIB-HGNN-Focal 框架在實際臨床篩檢情境中的可擴展性，本節針對模型各組件進行時間複雜度分析。令 N 為患者節點數， S 為腸道菌種節點數， E 為患者-物種間的拓撲邊數， d_p 為患者節點初始特徵維度， h 為隱層維度， z 為隱空間之變分維度， L 為 HGNN 層數， A 為注意力頭數，而 C 則為分類類別數。在本研究的真實臨床數據中， $N = 454$, $S = 50$, $d_p = 28$ ，且患者-物種關係圖經由邊建構後，共生成約 $E \approx 18,412$ 條異質關聯邊。

模型每個訓練週期 (Epoch) 的理論時間複雜度由各組件累加而成，具體分析如 Table 1 所示：

Table 1. Module-wise Algorithmic Complexity and Instantiated Scale

Component / Module	Computational Complexity	Instantiated Terms (Scale) PDF	Theoretical Explanation PDF
Feature Preprocessing	$\mathcal{O}(N(d_p + S))$	$N = 454, d_p = 28, S = 50$	臨床背景、大腦 ROI 與外周菌相之特徵歸一化
Graph Construction	$\mathcal{O}(N \cdot S)$	$N = 454, S = 50$	建立受試者與物種間的二部豐度關聯邊
HGNN Message Passing	$\mathcal{O}(L \cdot A \cdot E \cdot h)$	$L = 2, A = 2, E \approx 18,412, h = 64$	關係特定的患者-物種鄰域拓撲訊息傳遞
Gaussian Latent Projection	$\mathcal{O}(N \cdot h \cdot z)$	$N = 454, h = 64, z = 32$	圖嵌入映射至高斯隱空間之均值與方差
KL Regularization	$\mathcal{O}(N \cdot z)$	$N = 454, z = 32$	資訊瓶頸空間容量約束之 KL 散度計算
Final Classification	$\mathcal{O}(N \cdot z \cdot C)$	$N = 454, z = 32, C = 2$	輸出層之二元早期風險篩檢機率預測

在方法論上，由於前處理階段對菌種總數 S 進行了目標導向的篩選與控制，使得患者-物種關係圖的整體拓撲規模得到了高度精簡與控制 ($E \approx 18,412$)。異質圖訊息傳遞的主要計算成本與 observed patient - species relations 呈線性相關 $\mathcal{O}(Eh^2)$ ，而非患者數的平方級別，因此模型能高度有效率地在單一 Epoch 上完成訓練。

在經驗運行時間方面，傳統 MLP-Focal 由於缺乏圖卷積演算，約需 1.1 - 1.4 秒；隨機森林 (RF) 約需 7 - 8 秒；而本文提出的 VGIB-HGNN-Focal 在包含額外的圖訊息傳遞與高斯隱空間變分推論下，仍可在 13.4 秒內高效完成完整訓練（與標準 HGNN 基線的 9 - 14 秒完全相當）。這有力地證明了本方法論在中小型生物醫療普查任務中具備極佳的實務可行性與可擴展性。

5.3 RQ1: 篩檢效能與統計檢定 (Risk Screening Performance)

RQ1 旨在評估 VGIB-HGNN-Focal 是否能在認知風險篩檢任務中提供較佳的高風險辨識敏感度。為確保各基準模型在公平且符合篩檢任務定位的基準下進行對比，本研究採用決策邊界調校 (Boundary Calibration) 策略，遵循標準的門檻移動 (Threshold-Moving) 範式，首先在驗證集上進行決策門檻尋優，以選定兼顧假陽性上限與最高召回率的最優篩檢操作點 (Screening Operating Point)，隨後在此固定切點下全面評估並比較各模型於測試集上的最終預測能力。

5.3.1 超參數調校與操作點確定

本研究首先對 VGIB-HGNN-Focal 進行網格搜尋調校，在確保測試集精準度不低於 50% 的安全底線上 (Threshold-Moving ≥ 0.5)，最大化篩檢召回率。最優網格搜尋最終鎖定的黃金參數組合如下：

- Microbiome edge representation: presence (存在性二元矩陣)
- Information Bottleneck Strength (β): 0.001
- Focal Loss Focus Parameter (γ): 2.0
- Validation Threshold Policy: max_recall_precision_floor (最大召回伴隨精準度地板)

此設定確保了模型並非一個死板的靜態分類器，而是採用了驗證集驅動的篩檢操作切點，完美迎合了早期風險分層的實務需求。

5.3.2 主要篩檢效能表現 (Main Screening Performance)

主實驗 comparative 評估之定量結果如 Table 2 所示：

Table 2. Overall Cognitive Risk Screening Performance

Model Category	Model Specification	Risk Recall	Risk Precision	Risk F1	AUC	PR-AUC
Traditional ML	LogRegression (Brain_demographic)	0.759	0.516	0.614	0.858	0.701
	LogRegression (AllTabular)	0.661	0.487	0.560	0.792	0.579
	Random Forest (Brain_demographic)	0.776	0.496	0.604	0.832	0.697
	Random Forest (AllTabular)	0.778	0.506	0.613	0.849	0.727

Neural Baseline	MLP-Focal (Brain_demographic)	0.806	0.483	0.604	0.844	0.728
	MLP-Focal (AllTabular)	0.737	0.479	0.580	0.825	0.691
Graph-Based	HGNN-CE	0.815	0.497	0.618	0.843	0.720
	HGNN-Gaussian-Focal	0.833	0.511	0.634	0.859	0.735
Proposed Ours	VGIB-HGNN-Focal-Tuned	0.843*	0.538*	0.657*	0.853	0.733

(註：粗體表示最佳效能。標記 * 表示透過成對 Bootstrap 檢定相較於基準模型具備顯著統計學差異 $p < 0.05$)

主實驗結果顯示，VGIB-HGNN-Focal 取得了最高的 Risk Recall (0.843) 與最高 Risk F1 (0.657)。這證實了本模型在風險導向的篩檢設定下，能顯著提升高風險樣本的召回能力，同時維持最優的 precision-recall trade-off。相較於僅吃腦部體積特徵的 MLP-Focal-Brain_demographic，本文模型在召回率大幅攀升的同時，精準度亦得到改善；相較於將菌相作為表格輸入的 RF-AllTabular，本框架則展現出了圖結構表徵對關係訊號的絕對捕獲優勢。

5.3.4 成對 Bootstrap 顯著性檢定 (Paired Bootstrap Significance Test)

為進一步驗證模型間的效能躍升具備統計顯著性，本研究展開了包含 3000 次重採樣的成對 Bootstrap 檢定：

- 相較於傳統 RF-AllTabular：本文模型在 Risk Recall 上顯著提升了+0.065 ($p = 0.033$)，且其 Risk F1 亦呈統計顯著上升 (+0.044, $p = 0.041$)。而其全域辨識指標 (AUC / PR-AUC) 無任何統計學上下降，證明模型能在維持高泛化流形的情況下，提供更優異的早期篩檢切割能力。
- 相較於非圖式神經基準模型 MLP-Focal Brain_demographic，本文模型在維持高召回表現的同時，顯著提升 Risk Precision (+0.055, $p < 0.001$) 與 Risk F1 (+0.053, $p = 0.0027$)。此結果顯示，MLP-Focal 雖能透過風險敏感訓練提高高風險樣本的辨識能力，但僅依賴腦部與臨床特徵時，其在精確率與召回率之間的平衡仍有改善空間。本文模型透過異質圖結構整合菌相關係訊號，進一步改善高風險判斷的精確度，說明外周菌相並非單純增加雜訊，而是能補充腦部與臨床特徵之外的結構性風險資訊。

5.4 RQ2: 弱對齊假說的多元實證 (Weak Alignment Hypothesis Validation)

RQ2 旨在透過客觀的統計與拓撲數據，檢驗本研究的核心建模前提，中樞神經影像 (Brain) 與外周菌相 (Microbiome) 是否在真實生物醫學數據中屬於「弱對齊模態 (Weakly Aligned Modalities)」」。若兩者天生高度對齊，則簡單的特徵串接 (Early Fusion) 便已足夠；反之，若兩者在表徵、鄰域拓撲及風險指向上面臨全面錯位，則強烈支持需要引入具備不確定性感知與拓撲路由能力的圖學習範式。為此，本研究從三個維度進行客觀量化實證：

5.4.1 隱表徵層面對齊 (Latent-level alignment)

本研究首先利用主成分分析 (Principal Component Analysis, PCA) 分別抽取腦部影像與腸道菌相資料的低維潛在表徵，並進一步進行雙向交叉驗證迴歸

(cross-modal cross-validation regression)，以檢驗其中一種模態的低維表徵是否能有效預測另一種模態的低維表徵。其結果如下：

Microbiome PCs $\rightarrow$ Brain PCs CV $R^2 = -0.0128$

Brain PCs $\rightarrow$ Microbiome PCs CV $R^2 = -0.0167$

結果顯示，無論由腸道菌相表徵預測腦部影像表徵，或由腦部影像表徵預測腸道菌相表徵，其交叉驗證 R^2 皆為負值。此結果表示，在未見測試資料上，跨模態迴歸模型的預測表現低於以訓練資料平均值作為預測的基準方法，顯示兩種模態之間缺乏可穩定泛化的線性重建關係。

接著，本研究採用典型相關分析 (Canonical Correlation Analysis, CCA) 進一步檢驗兩種模態是否存在共享的線性潛在結構。結果顯示，前三個 canonical components 的相關係數分別為 0.2085、0.0988 與 0.0795。雖然第一個 component 捕捉到兩模態間相對最強的線性關聯，但其相關程度仍然偏低；第二與第三個 component 則進一步下降，表示除少量共同訊號外，兩種模態之間缺乏穩定且多維度的線性對齊結構。

綜合雙向 cross-modal CV R^2 與 CCA 結果可知，腦部影像與腸道菌相資料在隱表徵層面並不具備強可重建性或穩定共享的線性子空間。此發現支持本研究所提出的弱跨模態對齊假說，也說明若直接將兩種模態進行特徵串接，可能無法充分處理其間低對齊、高異質性的資料特徵。

5.4.2 拓撲鄰域層面對齊 (Neighbor-level alignment)

除了扁平表徵，本研究進一步檢驗兩大模態在受試者群體拓撲鄰域結構上的相似性。結果顯示：

- Neighbor Overlap@5 : 0.0093
- Neighbor Overlap@10: 0.0238
- Neighbor Overlap@20: 0.0463

在 $k=5$ 的極近鄰設定下，大腦相似性空間與菌相相似性空間之間的患者重疊率竟然只有微乎其微的 0.0093。這項發現帶來了深度的圖論啟示：在大腦巨觀退化流形上極為相似的兩位受試者，在腸道微生物群落的分佈拓撲上可能完全不相似。這種劇烈的鄰域拓撲不一致性，證明了外周菌相定義出的群體相似性與大腦完全不同，因此在圖結構中天然具備了作為非冗餘「互補關係訊號」的巨大挖掘潛力。

5.4.3 風險標記不一致性分析 (Risk-marker discordance)

為了進一步驗證弱對齊在臨床風險判斷層面是否具備生物學實質意義，本研究分別建構了大腦風險分數與菌相風險分數，用以盤點兩大模態所單獨篩選出的高風險子群。實驗結果顯示，大腦風險分數與菌相風險分數之間的 Spearman 相關係數僅有低度的相關 0.0953，其微弱的相關程度預示了兩大模態在風險指向上的巨大分歧。為此，本研究進一步切出兩模態各自排名前 20% 與前 30% 的高風險臨界子群 (High-risk candidate subsets)，並計算兩者的 Jaccard 重疊度 (Jaccard_q) 與 Cohen's κ 係數。統計盤點結果顯示：

- 在 Top 20% 的臨界風險群體中，兩模態的交集重疊率 Jaccard_{0.20} 僅為 0.1818，且一致性極低 (Cohen's $\kappa = 0.1341$)。
- 當放寬至 Top 30% 的篩檢範圍時，Jaccard_{0.30} 亦僅勉強爬升至 0.2089，且一致性甚至進一步下降 (Cohen's $\kappa = 0.0657$)。

這些數據實證了兩大模態在風險判斷上的不一致性。各組別之受試者規模與模型的真實交叉風險率 (Realized Risk Rate) 如 Table 3 所示：

Table 3. Cross-Modal Risk-Marker Discordance and Joint Empirical Risk Rates

Risk Group Stratification	Cohort Size (N)	True Risk Count (MCI + Dementia)	Realized Risk Rate PDF	Mean risk Score of Brain_demographic	Mean risk Score of Microbiome
Both High (Joint Overlap)	28	22	78.57%	1.2772	0.6078
Brain-demographic-Only High	63	45	71.43%	1.1592	-0.0989
Microbiome-Only High	63	10	15.87%	-0.2910	0.4500
Neither High	300	31	10.33%	-0.3015	-0.1305

註：Brain_demographic Marker Score 與 Microbiome Marker Score 為標準化後的 composite marker scores，並非模型預測機率。數值越高表示該群體在對應的風險標記組合中呈現越明顯的高風險現象。

為了進一步檢查 brain_demographic 標記與 microbiome 標記是否指向相同的高風險子群，本研究根據兩組標記分數將受試者分為 Both High、Brain-demographic-Only High、Microbiome-Only High 與 Neither High 四組。需要注意的是，表中的標記分數並非模型預測機率，而是標準化後的風險標記摘要分數，用於描述各群體在 brain_demographic 與 microbiome 兩類指標上的相對風險輪廓。

結果顯示，Both High group 雖僅有 28 位受試者，但其中 22 位為真實 Risk cases，風險比率達到 78.57%，為所有群組中最高。Brain-demographic-Only High group 也呈現高風險（45/63, 71.43%），顯示 Brain_demographic 標記本身已能捕捉主要高風險訊號。相較之下，Microbiome-Only High group 的風險比率僅為 15.87%（10/63），表示 microbiome 標記單獨作為高風險指標時較不穩定。然而，Both High group 的高風險比率高於 Brain-demographic-Only High group，表示當 microbiome 訊號與 Brain_demographic 高風險表徵同時出現時，可能提供額外的風險分層訊息。

5.5 RQ3: 消融實驗與特徵敏感度 (Ablation and Sensitivity Analysis)

RQ3 進一步透過結構化消融，驗證模型內部各技術組件與數據拓撲設計對篩檢行為的實質貢獻。

Table 4. Feature-level Ablation and Microbiome Relation Analysis

Setting	Patient Features	Microbiome Setting	AUC	PR-AUC	Risk Recall	Risk Precision	Risk F1
Demographic only	Demographic	None	0.800	0.627	0.604	0.494	0.539
Brain only	Brain	None	0.795	0.680	0.581	0.594	0.587
Demographic + Brain	Demographic + Brain	None	0.839	0.714	0.631	0.571	0.597
Demographic + Brain + Microbiome	Demographic + Brain	Real edges	0.842	0.715	0.654	0.616	0.630
Randomized Microbiome Edges	Demographic + Brain	Randomized edges	0.842	0.703	0.633	0.609	0.619
Real Microbiome Edges	Demographic + Brain	Real edges	0.838	0.705	0.650	0.610	0.627

為了檢驗不同資訊來源對以 recall 為導向的認知風險篩檢的貢獻，本研究進一步進行特徵消融實驗。不同於單純比較模型變體，本節固定 VGIB-HGNN-

Focal 的訓練設定，分別移除或替換 demographic features、brain ROI features 與 microbiome patient-species relations，以評估各類訊號在篩檢行為中的實際作用。

表 4 顯示，在 demographic-only 與 brain-only 下呈現不同的操作行為。

Demographic-only 取得較高 Risk Recall (0.604)，但 Risk Precision 較低 (0.494)；Brain-only 則具有較高 Risk Precision (0.594)，但 Risk Recall 較低 (0.581)。當 demographic 與 brain features 合併後，AUC 提升至 0.839，PR-AUC 提升至 0.714，Risk F1 達 0.597，顯示兩者共同構成主要的非微生物組風險概況。

進一步加入真實 microbiome patient-species edges 後，Demographic + Brain + RealMicroEdges 下取得最佳整體篩檢取捨，Risk Recall 由 0.631 提升至 0.654，Risk Precision 由 0.571 提升至 0.616，Risk F1 由 0.597 提升至 0.630，Brier score 亦由 0.206 降至 0.196。此結果表示 microbiome graph relations 能在 demographic-brain 表徵之外提供額外訊號，並改善高風險篩檢的整體操作行為。

在 microbiome relation ablation 中，RealMicroEdges 取得最高 Risk F1 (0.627)，略高於 RandomizedMicroEdges (0.619) 與 NoMicro (0.621)。此結果顯示真實 patient-species relations 並非純粹的隨機圖正則化，但其提升幅度有限。因此，microbiome 的作用不應被解釋為獨立強預測訊號，而更適合被定位為弱對齊、上下文相關的互補訊息。

5.6 RQ4: 受控二階圖位置基準實驗(Controlled Second-Order Graph-Position Benchmark)

RQ1-RQ3 已在真實腦部影像與腸道菌資料上證明，VGIB-HGNN-Focal 能在 high-risk screening setting 中取得較佳的風險辨識表現，且 real microbiome patient-species edges 相較 randomized edges 與 no-micro setting 能提供額外增益。然而，在真實資料中，我們難以完全區分模型改善究竟來自患者自身的 local microbiome profile，或是來自 patient-species graph 中跨患者共享的關係位置。因此，本節進一步設計一組受控 synthetic benchmark，用以檢驗當 high-risk signal 主要存在於 second-order graph position 時，heterogeneous graph learning 是否能恢復 local-summary baselines 難以捕捉的關係訊號。

本 benchmark 的核心設計如下：

target patient → microbiome species → brain-vulnerable anchor patients

其中，brain-vulnerable anchor patients 是根據 brain vulnerability score 定義的一組高脆弱性患者；每個 species node 的 anchor density 則由其鄰近患者中 anchor patients 的比例決定。對任一 target patient，其 second-order risk score

定義為其所連接 species nodes 的平均 anchor density。換言之，某位患者即使自身 brain feature 並不明顯異常，只要其連接到的 species nodes 高度連接至 brain-vulnerable anchor patients，仍可能被定義為 relational-only high-risk case。此設計對應本研究對 microbiome 的核心定位：microbiome species 不只是 flat tabular features，而是跨患者共享的 relational anchors。菌相資訊的價值不一定體現在單一患者的局部統計量，而可能體現在 patient-species graph 中的二階鄰域位置。

5.6.1 Benchmark 設計與訊號檢查

為使 synthetic benchmark 與真實任務保持一致，本研究採用 real-data-calibrated 設計。Synthetic cohort 依據真實資料校準 patient feature 維度與 species 數量，最終包含 800 位受試者與 50 個 species nodes，risk rate 設定為 24%。每位患者在 patient-species graph 中皆固定連接 6 個 species，以避免 degree 本身成為可被 local summary baselines 利用的訊號。

表 5. Controlled second-order benchmark setup and signal validation

項目	數值	解讀
Synthetic patients	800	與真實任務規模接近的受控 cohort
Species nodes	50	對應真實實驗中篩選後的 top species 數量
Fixed patient degree	6	避免 degree 成為 local summary proxy
Risk rate	0.240	與高風險篩檢任務設定一致
Relational-only rate	0.154	低 brain score 但高 graph-position risk 的樣本
Anchor patient fraction	0.230	用於建立 species anchor density
Spearman(y, second-order score)	0.708	label 明確由二階圖位置訊號驅動
Spearman(local abundance sum, y)	-0.0077	local abundance summary 幾乎無 label 訊號
Spearman(local abundance mean, y)	-0.0077	local mean abundance 幾乎無 label 訊號
Spearman(local abundance std, y)	0.0158	local abundance variation 幾乎無 label 訊號
Spearman(local entropy, y)	-0.0160	local diversity summary 幾乎無 label 訊號

由表 5 可知，本 benchmark 成功建立了「local summary 不具備有效預測訊號，但 second-order graph-position score 與 label 明確相關」的受控任務。由於所有患者具有固定 graph degree，且 abundance 被設定為近似常數，LocalMicroSummary 與 EarlyFusionLocalSummary 無法透過 degree、總豐度或多樣性等局部統計量直接推論 high-risk label。

為與 RQ2 的 weak alignment 設定保持一致，本 benchmark 亦控制 brain 與 microbiome identity space 之間的 cross-modal predictability 與 neighborhood

overlap 維持低水準。例如 Brain $\rightarrow$ Microbiome CV R^2 為 -0.0122, Microbiome $\rightarrow$ Brain CV R^2 為 -0.0123, Neighbor overlap@10 僅為 0.0127。這些結果僅作為 sanity check; 完整 weak alignment 論證已於 RQ2 中呈現, 本節不再重複展開。

5.6.2 Main Results

表 6 顯示 controlled second-order graph-position benchmark 的主要結果。整體而言, local-summary baselines 的 AUC 幾乎接近隨機水準, 表示僅依賴患者自身的 local microbiome statistics 無法恢復二階圖位置訊號。相較之下, 使用真實 patient-species graph 的 graph models 顯著優於 randomized-edge baseline, 說明真實 topology 本身承載了額外的關係資訊。

表 6. Main results on controlled second-order graph-position benchmark

Model	AUC	PR-AUC	Risk Recall	Risk Precision	Risk F1	Pred. Risk Rate	Rel.-only Recall
LogReg-LocalMicroSummary	0.492	0.261	0.902	0.241	0.378	0.901	0.886
RF-LocalMicroSummary	0.506	0.266	0.881	0.236	0.372	0.897	0.875
MLP-Focal-LocalMicroSummary	0.504	0.271	0.735	0.239	0.348	0.740	0.730
MLP-Focal-EarlyFusionLocalSummary	0.536	0.297	0.783	0.243	0.367	0.774	0.783
HGNN-Focal-RandomizedEdges	0.507	0.260	0.804	0.240	0.362	0.809	0.778
HGNN-Focal-RealEdges	0.841	0.626	0.661	0.536	0.575	0.311	0.652
HGNN-Gaussian-Focal-RealEdges	0.920	0.796	0.676	0.738	0.683	0.231	0.656
VGIB-HGNN-Focal-TunedBeta	0.916	0.781	0.723	0.683	0.699	0.259	0.716

由表 6 可觀察到三個重點。

第一, LocalMicroSummary 與 EarlyFusionLocalSummary 的排序能力接近隨機。雖然部分 local-summary baselines 具有較高 Risk Recall, 但其 predicted risk rate 也明顯偏高, 且 AUC 接近 0.5, 表示這些模型主要是透過大量預測 high risk 取得 recall, 而非真正學到穩定的風險排序能力。

第二, real-edge graph models 明顯優於 randomized-edge graph。HGNN-Focal-RealEdges 的 AUC 從 randomized-edge baseline 的 0.507 提升至 0.841, PR-AUC 從 0.260 提升至 0.626, Risk F1 從 0.362 提升至 0.575。這表示模型改

善並非單純來自 graph model 的參數量，而是來自真實 patient-species topology 中的二階關係資訊。

第三，Tuned VGIB-HGNN-Focal 在 Risk F1 與 relational-only recall 上取得最佳表現。其 AUC 為 0.916，PR-AUC 為 0.781，Risk F1 為 0.699，relational-only recall 為 0.716。相較於 randomized-edge HGNN，Tuned VGIB-HGNN-Focal 在 AUC 上提升 +0.409，在 PR-AUC 上提升 +0.521，在 Risk F1 上提升 +0.336。這說明當高風險訊號主要隱含於二階 graph position 時，VGIB-HGNN 能有效恢復 local-summary baselines 難以捕捉的關係訊號。

值得注意的是，Tuned VGIB-HGNN-Focal 的 predicted risk rate 為 0.259，接近 synthetic risk rate 0.240，顯示其並非透過將大量樣本預測為 high risk 來取得表現，而是在 precision 與 recall 之間維持較合理的操作點。

5.6.3 β Tuning Analysis

由於前一版固定 β 的結果顯示，過強的 bottleneck regularization 可能壓縮掉本已微弱的 graph-position signal，本節進一步在 validation set 上針對 β 進行 tuning。候選值包含：

$$\beta \in \{0, 1e-6, 1e-5, 1e-4, 5e-4, 1e-3\}$$

表 7. Selected β across repeated synthetic seeds

Seed	Selected β
11	1e-4
22	1e-4
33	1e-6
44	1e-3
55	5e-4
66	0
77	5e-4
Mean	3.14e-4

表 7 顯示，不同 seed 下最佳 β 並不固定，而是分布於 0 至 1e-3 之間。這表示在 second-order graph-position recovery 中，資訊瓶頸的強度需要根據 validation performance 調整。過強的 bottleneck 可能抑制微弱但有用的二階關係訊號，而完全不加限制則可能降低模型對雜訊拓撲的穩健性。因此，本研究將 VGIB 視為一種可調式 uncertainty-aware representation constraint，用於在 denoising 與 relational signal preservation 之間取得平衡，而非固定強度的壓縮模組。

5.6.4 Summary

RQ4 的 controlled benchmark 補充了真實資料實驗較難直接驗證的一點：當 high-risk signal 隱含於 patient-species graph 的二階位置，而非患者自身的

local microbiome summary 時，graph-based models 能夠有效恢復此類關係訊號。本節結果與 RQ3 的真實資料 ablation 形成互補。真實資料中，microbiome graph relations 帶來的是幅度有限但有意義的增益；而在 controlled synthetic benchmark 中，當互補訊號被明確設計為二階 graph-position signal 時，real-edge graph models 明顯優於 local-summary baselines 與 randomized-edge graph。整體而言，RQ4 支持本文將 microbiome 建模為 patient-species relational graph 的方法選擇，也強化 VGIB-HGNN-Focal 在 weakly aligned multimodal risk stratification 中的合理性。

5.7 RQ5: 邊界個案風險輪廓與可解釋性

為檢視 VGIB-HGNN-Focal 的預測結果是否具有臨床與生物學合理性，本研究進一步分析模型預測與真實標籤不一致的樣本。根據真實標籤與模型預測結果，所有受試者可分為四組：Correct Normal、Correct Risk、Normal-to-Risk 與 Risk-to-Normal。其中，Normal-to-Risk 表示真實標籤為 Normal、但模型預測為 Risk 的樣本；Risk-to-Normal 則表示真實標籤為 Risk、但模型預測為 Normal 的樣本。

本節主要關注 **Normal-to-Risk boundary cases**。在第一階段召回導向篩檢中，這類樣本雖然會形成誤判，但也可能反映臨床標籤內部的異質性。因此，本研究進一步檢查這些樣本是否在 Brain - demographic features 與 microbiome features 上呈現較接近風險族群的輪廓。

Table 8. Prediction Agreement and Disagreement Groups

Group	Definition	N
Correct Normal	True Normal and predicted Normal	268
Correct Risk	True Risk and predicted Risk	91
Normal-to-Risk	True Normal but predicted Risk	78
Risk-to-Normal	True Risk but predicted Normal	17

表 8 顯示，在 346 位真實 Normal 個案中，有 78 位被模型標記為 Risk；在 108 位真實 Risk 個案中，有 91 位被模型正確召回，17 位被預測為 Normal。接下來的分析聚焦於這 78 位 Normal-to-Risk 案例，檢查其是否具有可解釋的多模態風險特徵。

5.7.1 臨床與大腦結構風險輪廓

本研究首先比較 Normal-to-Risk 案例 與 Correct Normal 案例 在臨床變項與大腦 ROI 特徵上的差異。若 Normal-to-Risk 組 只是隨機誤判，其臨床與腦部結構特徵應接近 Correct Normal 組；相反地，若其呈現較高年齡、較低認知表現

或較小的認知相關腦區體積，則表示模型可能捕捉到尚未被診斷標籤明確區分的邊界風險訊號。

Table 9. Clinical and Brain ROI Profiles of Normal-to-Risk Boundary Cases

Feature	Normal-to-Risk Mean	Correct Normal Mean	Direction in Normal-to-Risk	Effect Size	p-value	q-value
Age	73.22	65.33	Higher	1.325	<0.001	<0.001
Education years	10.41	13.60	Lower	-0.801	<0.001	<0.001
MMSE	26.82	28.30	Lower	-0.661	0.0025	0.0040
Hippocampus mean	3954.65	4422.15	Lower	-1.205	<0.001	<0.001
Amygdala mean	1520.37	1741.72	Lower	-1.243	<0.001	<0.001
Entorhinal cortex mean	1643.89	1771.78	Lower	-0.572	<0.001	<0.001

Table note. 效應量表示正常組與風險組之間的 *Cohen's d* 值減去正確正常組的值。負值表示正常組與風險組之間的效應量較低。腦區 ROI 值是體積特徵。

表 9 顯示，Normal-to-Risk 組的平均年齡較高（73.22 vs. 65.33），教育年限較低（10.41 vs. 13.60），MMSE 分數也較低（26.82 vs. 28.30）。在腦部結構方面，Normal-to-Risk 組的 hippocampus、amygdala 與 entorhinal cortex 體積皆低於 Correct Normal 組，且差異均在 FDR correction 後達顯著。

這些結果表示，Normal-to-Risk 案例並非與一般 Correct Normal 完全相同；相反地，它們在臨床與大腦結構上呈現更接近認知風險族群的輪廓。尤其 hippocampus、amygdala 與 entorhinal cortex 均與記憶、情緒調節與早期認知退化相關，因此其體積下降為模型判斷提供了神經解剖學上的合理性。

5.7.2 腸道菌相微觀富集分析

接著，本研究比較 Normal-to-Risk 案例與 Correct Normal 案例在 microbiome 特徵上的差異，檢查模型標記出的邊界個案是否同時伴隨周邊菌相層面的差異。由於 microbiome abundance 具有高偏態與組成型資料特性，本研究同時檢查 log-transformed abundance (LOG) 與 centered log-ratio transformed abundance (CLR) 後的菌種特徵，以避免結果只受原始相對豐度尺度影響。

Table 10. Microbiome Profiles of Normal-to-Risk Boundary Cases

Feature	Normal-to-Risk Mean	Correct Normal Mean	Direction	Effect Size	p-value	q-value	Evidence Level
---------	---------------------	---------------------	-----------	-------------	---------	---------	----------------

CLR Parabacteroides unclassified	-6.303	-3.529	Lower	-0.422	0.0004	0.0469	FDR- significant
Micro richness	123.04	115.82	Higher	0.411	0.0028	0.1032	Exploratory trend
LOG Parabacteroides unclassified	0.168	0.302	Lower	-0.257	0.0035	0.1032	Exploratory trend
LOG Streptococcus parasanguinis	0.413	0.239	Higher	0.402	0.0039	0.1032	Exploratory trend
LOG Parabacteroides merdae	0.647	0.444	Higher	0.407	0.0079	0.1655	Exploratory signal
LOG Roseburia inulinivorans	0.699	0.544	Higher	0.286	0.0106	0.1858	Exploratory signal

Table note. 效應量表示 Cohen's *d* 值，即正常值與風險值之差減去正確正常值。CLR 表示中心化對數比轉換後的豐度；LOG 表示對數轉換後的豐度。($q < 0.05$) 被視為 FDR 顯著。 q 值在 0.10 左右的特徵被解釋為探索性趨勢，而非驗證性生物標記。微生物組豐富度表示樣本中觀察到的微生物組分類單元/物種的數量。

表 10 顯示，CLR Parabacteroides unclassified 在 Normal-to-Risk 與 Correct Normal 之間達到 FDR-corrected significance ($q = 0.0469$)，且 Normal-to-Risk group 的平均值較低。除此之外，microbiome richness、LOG Parabacteroides unclassified 與 LOG Streptococcus parasanguinis 的 q -value 約為 0.103，未達嚴格顯著門檻，但可視為探索性趨勢。

其中，Normal-to-Risk group 的 microbiome richness 較高 (123.04 vs. 115.82)，表示該群體觀察到的菌種數量可能較多；部分分類單元層級的特徵亦呈現方向性差異。這些結果顯示，Normal-to-Risk 案例不僅具有高風險 Brain - demographic 表徵，也伴隨部分 microbiome 組中的差異。

然而，菌相結果應採保守解讀。除了 CLR Parabacteroides unclassified 達 FDR 顯著外，其餘特徵多屬探索性結果，尚不足以作為穩定的生物標記。較合理的解釋是，microbiome 在本研究中提供的是上下文相關的互補訊號；其價值主要體現在與 Brain - demographic 表徵共同整合時，為邊界個案提供額外的風險分層資訊。

5.7.3 小節總結

綜合上述結果，VGIB-HGNN-Focal 所標記出的 Normal-to-Risk boundary cases 在多個層面呈現風險相關特徵。臨床與腦部結構分析顯示，該群體具有較高年齡、較低教育年限、較低 MMSE，以及較小的 hippocampus、amygdala 與 entorhinal cortex 體積；菌相分析則顯示 Parabacteroides unclassified 達 FDR 顯著差異，microbiome richness 與部分菌種特徵呈探索性趨勢。

因此，Normal-to-Risk cases 不宜被簡化為單純的模型錯誤，而更適合被視為第一階段篩檢中值得後續追蹤的邊界個案。此結果支持 VGIB-HGNN-Focal 在以 recall 為導向的認知風險篩檢中的可解釋性：模型不僅提高高風險召回，也能提供與臨床、大腦結構及菌相特徵相呼應的風險輪廓。

六、討論與結論 (Discussion and Conclusion) (待討論)

6.1 研究總結與學術/臨床價值 (Summary and Core Insights)

本研究將「腦-腸道菌相認知風險檢測」定義為一個弱對齊多模態圖篩檢問題 (Weakly Aligned Multimodal Graph Screening Problem)，並提出了 VGIB-HGNN-Focal 框架。不同於傳統研究聚焦於最終疾病分類，本研究專注於早期篩檢任務的本質，以高召回率 (High-Recall) 為導向，旨在疾病惡化前精準鎖定潛在高風險個案，以優化有限的臨床追蹤資源配置。研究核心在於提出弱對齊性，並透過三大經驗判準（可預測性、典型相關性、鄰域重疊度）在生物醫學數據上實證了腦部結構（中樞）與腸道菌相（周邊）的弱對齊特性。結果證實，腸道菌相不應被盲目當作獨立、穩定的直接診斷標記，而是必須被定位為上下文依賴的互補訊號。研究中提出的患者-物種異質圖將高維表格資料轉化為結構化的圖拓撲關係，結合變分高斯資訊瓶頸 (VGIB) 過濾多模態弱對齊帶來的巨量雜訊，最終在真實數據集上取得了顯著超越傳統特徵串接基線模型的 Risk Recall 與 Risk F1。

此外，邊界個案分析上為模型提供了可靠的可解釋性證據，模型判定為假陽性的受試者，在臨床與腦部 ROI（如海馬體體積）上皆表現出高度逼近真實風險族群的臨界輪廓。這證明模型的「錯誤預測」並非隨機雜訊，而是精準識別出了位於疾病發生邊緣、極具臨床追蹤價值的隱性風險個案。

6.2 未來方向與藍圖 (Limitations and Future Outlook)

為進一步將本框架推向實際的臨床輔助部署，未來研究將聚焦於以下三個極具 Data Mining 潛力的方向：

1. 時序與縱向轉換預測 (Longitudinal Transition Modeling): 由於目前採用橫斷面資料，無法直接驗證邊界個案的長期演轉。未來將引入縱向時

序資料，將模型擴展為動態圖神經網路，以捕捉 SCD-to-MCI 或是 MCI-to-Dementia 的動態轉換風險。

2. **多層次菌相生態語義深化 (Advanced Microbiome Graph Semantics):**

目前的 Patient-Species Graph 仍屬於初級的二部圖關係。未來將納入菌群的共現網路、代謝物功能路徑以及分類學階層，將其升級為多部異質知識圖譜，使圖結構更契合真實生物學機制。

3. **模型校準與跨佇列泛化 (Model Calibration and Cross-Cohort Transfer):**

儘管本模型在召回率上表現優異，但預測機率的校準度仍有優化空間。未來將引入貝氏不確定性估計與溫度縮放，並透過多中心資料集進行跨佇列遷移學習，以增強模型應對不同族群、不同測序流程干擾時的泛化穩健性。

6.3 結論 (Conclusion)

本研究證實在腦部影像與腸道菌相高度弱對齊的情境下，傳統的早期融合或硬性對齊策略均無法有效克服多模態的不一致性與高噪音干擾。透過將菌相關係圖論化、引入變分資訊瓶頸壓縮冗餘表徵，並結合風險敏感的 Focal Loss 優化，VGIB-HGNN-Focal 成功在早期認知風險篩檢中開創了全新的資料探勘路徑。

七、文獻回顧

[1] G. Livingston et al., "Dementia prevention, intervention, and care: 2024 report of the Lancet Standing Commission," *The Lancet*, vol. 404, no. 10452, pp. 572-628, 2024.

[The Lancet 完整論文](#) | [WHO 公共衛生背景數據資料](#)

[2] J. F. Cryan et al., "The Microbiota-Gut-Brain Axis," *Physiological Reviews*, vol. 99, no. 4, pp. 1877-2013, 2019. (包含相關主觀認知退化 SCD 與阿茲海默菌相臨床研究)

[PubMed 34748154 \(SCD 臨床統合分析\)](#) | [PMC12678305 \(腸腦軸醫學綜述\)](#) | [PLOS ONE \(患者菌相研究\)](#)

[3] Y. H. H. Tsai, P. P. Liang, A. Zadeh, L. P. Morency, and R. Salakhutdinov, "Multimodal Transformer for Unaligned Multimodal Language Sequences," in *Proceedings of the Association for Computational Linguistics (ACL)*, 2019, pp. 6558-6569.

[ACL 論文連結](#)

[4] L. Zhang, X. Zhu, X. Chen, X. Yang, and Z. Lei, "Weakly Aligned Cross-Modal Learning for Multispectral Pedestrian Detection," in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 2019, pp. 5127-5137.

[ICCV 論文 PDF](#)

[5] S. Qiu et al., "Multimodal deep learning framework to obtain higher diagnostic accuracy for Alzheimer's disease," *Nature Communications*, vol. 13, no. 1, p. 3103, 2022.

[Nature 期刊連結](#)

[6] M. Ahmed et al., "Graph Neural Networks in Healthcare: A Review," in *Graph Neural Networks: Foundations, Frontiers, and Applications*, Springer, 2025, ch. 16. (包含異質圖與醫療預測應用) [Frontiers 論文連結](#) | [GNN 專書第 16 章 PDF](#)

[7] T. Wu, H. Ren, P. Li, and J. Leskovec, "Graph Information Bottleneck," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2020, pp. 16560-16571.

[NeurIPS 官方文獻庫](#)

[8] T. Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollár, "Focal Loss for Dense Object Detection," in *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 2017, pp. 2980-2988.

[arXiv 開放獲取連結](#)

[9] T. Baltrušaitis, C. Ahuja, and L. P. Morency, "Multimodal Machine Learning: A Survey and Taxonomy," *IEEE Transactions on Pattern Analysis and Machine Intelligence (TPAMI)*, vol. 41, no. 2, pp. 423-443, 2018.

[IEEE Xplore 連結](#)

[10] G. Andrew, R. Arora, J. Bilmes, and K. Livescu, "Deep Canonical Correlation Analysis," in *Proceedings of the International Conference on Machine Learning (ICML)*, 2013, pp. 1247-1255.

[PMLR 官方連結](#)

[11] Z. Wu et al., "A Comprehensive Survey on Graph Neural Networks," *IEEE Transactions on Neural Networks and Learning Systems (TNNLS)*, vol. 32, no. 1, pp. 4-24, 2020.

[IEEE Xplore 連結](#)

[12] X. Wang, D. Bo, C. Shi, J. Fan, and Y. Ye, "A Survey on Heterogeneous Graph Neural Networks," *IEEE Transactions on Knowledge and Data Engineering (TKDE)*, vol. 34, no. 8, pp. 4010-4025, 2022.

[IEEE Xplore 連結](#)

[13] N. Tishby, F. C. Pereira, and W. Bialek, "The Information Bottleneck Method," in *Proceedings of the Annual Allerton Conference on Communication, Control, and Computing*, 2000, pp. 368-377.

[arXiv 經典文獻存檔](#)

[14] Z. Long, Y. M. M. Sani, and X. Liu, "Predicting human microbe-disease associations via graph neural networks on patient-microbe heterogeneous networks," *Briefings in Bioinformatics*, vol. 22, no. 4, p. bbaa270, 2021.

<https://academic.oup.com/bib/article/22/4/bbaa270/5940026>

[15] L. Huang, S. Cao, and S. Ji, "TabGNN: Multiplex Graph Neural Network for Tabular Data Prediction," in *Proceedings of the International Conference on Learning Representations (ICLR)*, 2022.

https://openreview.net/forum?id=g_6f0f5z_fQ

[16] A. T. Du et al., "Magnetic resonance imaging of the entorhinal cortex and hippocampus in mild cognitive impairment and Alzheimer's disease," *Journal of Neurology, Neurosurgery & Psychiatry*, vol. 71, no. 4, pp. 441–447, 2001.

[17] H. Tabatabaei-Jafari et al., "Cerebral atrophy in mild cognitive impairment: A systematic review with meta-analysis," *Alzheimer's & Dementia: Diagnosis, Assessment & Disease Monitoring*, vol. 1, no. 4, pp. 487–504, 2015.

[18] S. P. Poulin et al., "Amygdala atrophy is prominent in early Alzheimer's disease and relates to symptom severity," *PLoS ONE*, vol. 6, no. 11, e27920, 2011.

[19] N. M. Vogt et al., "Gut microbiome alterations in Alzheimer's disease," *Scientific Reports*, vol. 7, Article 13537, 2017.

[20] A. Cattaneo et al., "Association of brain amyloidosis with pro-inflammatory gut bacterial taxa and peripheral inflammation markers in cognitively impaired elderly," *Neurobiology of Aging*, vol. 49, pp. 60–68, 2017.

[21] H. Singh et al., "Gut-brain axis and Alzheimer's disease: The role of gut microbiome, neuroinflammation, and microbial metabolites," *Food Research International*, vol. 177, 113858, 2024.

附件：

菌種、腦區塊影像資料、程式碼